

דוח איסוף וניתוח נתונים - חלק א'

מגישות: שרה דרעי ושישראל עמר

1. החלטות שנלקחו בבניית סט הנתונים

במהלך עבודה על הפרויקט, נלקחו מספר החלטות שהן:

בחרנו להביא את הקבצים ישר מהאתר כדי לאפשר הורדה נוחה לכל משתמש שיקרא את הקוד שלנו.

```
BASE_URL = "https://datasets.imdbws.com/"

folders = {
    "basics": "title.basics.tsv.gz",
    "ratings": "title.ratings.tsv.gz",
    "principals": "title.principals.tsv.gz",
    "names": "name.basics.tsv.gz"
}

def download_file(folder_name):
    url = BASE_URL + folder_name
    response = requests.get(url, stream=True)
    return io.BytesIO(response.content)

basics_file = download_file(folders["basics"])
ratings_file = download_file(folders["ratings"])
principals_file = download_file(folders["principals"])
names_file = download_file(folders["names"])
```

לאחר מכן החלטנו לחלק את הנתונים ל-chunks של 100,000 שורות, מכיוון שהקבצים כבדים מאוד כך ניתן לשמור את הנתונים חלק-חלק, ובמקרה של קריסה פתאומית, חלק מהנתונים כבר שמור. משם סיננו תכנים מסוג "סרט" והסרטים המתחילים ב-K וב-N.

```
basics_chunks = []
for chunk in pd.read_csv(basics_file,
    sep="\t",
    na_values="",
    on_bad_lines="skip",
    compression="gzip",
    low_memory=False,
    chunksize=100_000):

    chunk = chunk[(chunk["titleType"] == "movie") &
        (chunk["primaryTitle"].str.startswith(("K", "k", "N", "n"), na=False))]
    basics_chunks.append(chunk)

basics = pd.concat(basics_chunks, ignore_index=True)
```

לאחר שכל הטבלאות הועלו, שמרנו רק את העמודות הרלוונטיות והחשובות.

```

basics= basics.drop(columns=["originalTitle", "isAdult", "endYear"])
principals= principals.drop(columns=["ordering", "job", "characters"])
names= names[["nconst"]]

```

לאחר מכן ביצענו כל מיני סינונים :

את העמודה category ושמרנו רק את האנשים מסוג actor או actress
השארנו סרטים שיוצרו רק עד שנה 2024 כולל ושמשך הסרט בין 60 ל 300 דקות
החלטנו לקחת סרטים שמספר ההצבעות גדול מ 100

```

In [16]: principals= principals[principals["category"].isin(["actor", "actress"])]

```

```

df= df[df["startYear"] <= 2024]
df["runtimeMinutes"]= pd.to_numeric(df["runtimeMinutes"], errors="coerce")
df= df[(df["runtimeMinutes"] >= 60) & (df["runtimeMinutes"] <= 300)]

```

```

In [28]: df = df[df["numVotes"] >= 100]

```

הגענו לרגע של המיזוג של הטבלאות. לטבלאות ratings ו-basics היה המפתח המשותף tconst, ולטבלאות names ו-principals היה המפתח המשותף nconst. בנוסף, מכיוון ש-principals הכיל גם את tconst, יכולנו לאחד את כל ארבע הטבלאות לטבלה אחת כוללת.

```

In [18]: principals_names = principals.merge(names, on="nconst", how="left")

```

```

In [19]: df=basics.merge(ratings, on="tconst", how="left")

```

```

In [20]: df= df.merge(principals_names, on="tconst", how="left")

```

יצרנו פונקציה שיוצרת עמודה חדשה של lead actor ids, המכילה את ה-5 שחקנים הראשונים של כל סרט.

```

In [25]: top5 = (df[df["category"].isin(["actor", "actress"])]
            .groupby("tconst")["nconst"]
            .apply(lambda x: list(x)[:5])
            .reset_index()
            .rename(columns={"nconst": "lead_actors_ids"}))
df = df.merge(top5, on="tconst", how="left")

```

אחרי שהסט נתונים שלנו נקי ומסונן לפי ההנחיות, הגענו לשלב של webscrapping של wikipedia. בנינו פונקציה clean כדי לקבל נתונים שכתובים בצורה תקינה. לאחר מכן את פונקציית normalize כדי לנרמל טקסט על ידי המרתו לאותיות קטנות, הסרת סימני פיסוק וחזרת קבוצת המילים.

ולסיום בנינו פונקצייה של `get moovies infos` על מנת לקחת את הנתונים שאנחנו צריכים (language,country,budget,boxoffice,plot) מהדף `wikipedia`.

שולחים לויקיפדיה את שם הסרט והשנה, ומקבלים בחזרה רשימת דפים מתאימים. בוחרים את הדף שהכי קרוב למה שחיפשנו. נכנסים לדף שמצאנו וסורקים אותו. לוקחים מהטבלה הצדדית את השפה, המדינה, התקציב וההכנסות, ומהגוף של הדף את ה-`plot`.

לבסוף ספרנו את הערכים החסרים והצגנו אותם

```
In [ ]: final_df.isna().sum()
```

2. תיאור שדות הנתונים

העמודות בסט הנתונים הסופי, כפי שמופיע בקוד:

מקור הנתון	טיפוס נתון	תיאור	שם עמודה
(IMDb (Basics	String	מזהה ייחודי של הסרט (אלפא-נומרי)	<code>tconst</code>
(IMDb (Basics	String	סוג הכותר (סוג ל-'movie')	<code>titleType</code>
(IMDb (Basics	String	שם הסרט המקורי/ראשי	<code>primaryTitle</code>
(IMDb (Basics	Integer	שנת יציאת הסרט	<code>startYear</code>
(IMDb (Basics	Float/Int	משך הסרט בדקות	<code>runtimeMinutes</code>
(IMDb (Basics	String	ז'אנרים (מופרדים בפסיקים)	<code>genres</code>
(IMDb (Ratings	Float	דירוג ממוצע של גולשים	<code>averageRating</code>

numVotes	מספר המדרגים ב-IMDb	Float	(IMDb (Ratings
nconst	מזהה ייחודי של שחקן (מפתח למיזוג)	String	(IMDb (Names
category	תפקיד בצוות (למשל: actor, actress)	String	IMDb (Principals
lead_actors_ids	רשימת מזהי השחקנים המובילים (עד 5)	List	יצרנו את העמודה
language	שפת הסרט	String	Wikipedia
country	מדינת מקור	String	Wikipedia
plot	תקציר עלילתי	String	Wikipedia
budget	תקציב הסרט	String	Wikipedia
boxOffice	הכנסות הסרט	String	Wikipedia

3. היקף הנתונים שנאספו

לאחר ביצוע כל הסינונים (סוג כותר, אורך סרט, שנת הפקה וכמות הצבעות מינימלית), סט הנתונים הסופי כולל:

6,455 סרטים ייחודיים.

4. ניתוח ערכים חסרים (Missing Values)

שיעור הערכים החסרים בסט הנתונים הסופי:

שם עמודה	מספר ערכים חסרים	אחוז מהכלל
tconst, titleType, primaryTitle, startYear, runtimeMinutes, averageRating, numVotes	0	0%
genres	16	0.25%
nconst, category, lead_actors_ids	289	4.48%
language	2,944	45.61%
country	2,963	45.90%
plot	3,637	56.34%
boxOffice	5,193	80.45%
budget	5,479	84.88%

ניתן לראות כי נתוני הליבה מ-IMDb כמעט מלאים, בעוד שנתוני ויקיפדיה סובלים משיעור חסר גבוה מכיוון שלא לכל סרט קיים ערך בוויקיפדיה באנגלית, או שהמידע לא הוזן ב-Infobox.